

Progress Report

Arthur Sophiatti (asophiatti@student.uc.pt)
Maria Amaral (uc2022247445@student.uc.pt)

Introdução

A pandemia de COVID-19 foi um dos eventos mais marcantes da última década, tendo um impacto não só ao nível da saúde pública, mas também nas economias nacionais. Entre confinamentos, quebras no PIB, aumento do desemprego e pacotes de estímulo governamentais, o foco deste projeto é mostrar o que realmente aconteceu através dos dados.

Com este projeto, procura-se democratizar o acesso à informação sobre a COVID-19 e o seu impacto económico em vários países, transformando dados em visualizações interativas, claras e acessíveis.

O público-alvo deste projeto inclui:

- Estudantes/investigadores das áreas da economia, gestão, ciência de dados e políticas públicas;
- Jornalistas que precisam de contextualizar dados económicos;
- Decisores e analistas que pretendem comparar o impacto da pandemia entre países;
- Cidadãos curiosos que querem compreender como uma crise sanitária se traduziu numa crise económica.

Trabalhos Relacionados

Para orientar o desenvolvimento do projeto, analisámos diferentes dashboards e plataformas de referência na visualização de dados sobre a COVID-19 e o seu impacto global.


Estas fontes irão servir como base conceptual e visual, tanto ao nível da estrutura como das técnicas de comunicação adotadas.

World Health Organization - COVID-19 Dashboard


[COVID-19 circulation | WHO COVID-19 dashboard](#)

Este dashboard apresenta a monitorização global da pandemia, funcionando simultaneamente como ferramenta informativa e como mecanismo de transparência institucional.

Apresenta uma visualização clara da circulação do vírus a nível mundial, tem uma abordagem acessível tanto para o público geral como especialistas e uma estrutura organizada com foco na credibilidade dos dados.




SARS-CoV-2 PCR percent positivity



Associação Portuguesa de Geógrafos - Dashboard COVID-19 Portugal

[Dashboard | Covid-19 PT | Associação Portuguesa de Geógrafos](#)

Este dashboard foca-se no contexto nacional, privilegiando a análise espacial dos dados. Além disso, utiliza mapas interativos detalhados com informação segmentada por região e um grande foco na componente geográfica da propagação do vírus.





Rádio Renascença - Mapas e Números do Coronavírus

[Mapas e Números do Coronavírus](#)

Este portal apresenta uma abordagem mais jornalística e modular à visualização de dados. As suas principais diferenças são:

- a organização por módulo temático;
- visualizações variadas;
- forte componente comunicativa.






Our World in Data

[COVID-19 Pandemic - Our World in Data](#)

É uma das plataformas mais reconhecidas a nível mundial, combinando rigor científico com excelente clareza visual. Este site terá grande relevância para o projeto uma vez que é a fonte principal dos dados.

Além disso, este site engloba indicadores epidemiológicos e económicos e visualizações interativas orientadas para a análise comparativa.



Requisitos de Design

O projeto pretende alcançar pessoas com diferentes níveis de literacia estatística, com uma necessidade comum: compreender as relações entre indicadores de saúde e de económicos.

Com esta visualização, pretende-se responder, também, a uma série de questões:

- Como evoluíram os casos e mortes por COVID-19 ao longo do tempo em cada país?
- Como evoluiu o PIB nos mesmos períodos?
- Existe relação temporal entre picos de COVID-19 e variações no PIB?
- Que países demonstraram maior resiliência económica?
- O impacto foi uniforme ou desigual entre países?

Em termos de requisitos de design, ao longo da realização deste projeto, serão seguidas as seguintes linhas orientadoras:

1. Suporte de comparação entre países
 - a. Permitir selecionar um ou vários países;
 - b. Comparar indicadores lado a lado;
 - c. Evidenciar diferenças de intensidade, timing e recuperação.
2. Exploração temporal clara e fluída
 - a. Existência de controlo de intervalo temporal;
 - b. Possibilitar foco num período de tempo específico;
 - c. Mudanças temporais visualmente evidentes.
3. Relação entre indicadores de saúde e económicos
 - a. Cruzar variáveis (ex.: casos vs. variação do GDP);
 - b. Identificar padrões, correlações ou desfasamentos temporais;
 - c. Comparar intensidade do impacto sanitário com impacto económico.
4. Suporte à análise exploratória
 - a. Permitir filtrar, destacar e comparar dinamicamente;
 - b. Facilitar identificação de outliers;
 - c. Apoiar exploração livre e descoberta de padrões.
5. Redução de carga cognitiva
 - a. USo consistente de cores;
 - b. Escalas claras e comparáveis;
 - c. Legendas explícitas;
 - d. Evitar *clutter* visual.
6. Interação avançada
 - a. implementar, pelo menos, uma técnica de interação avançada (ex.: *linking* ou *brushing*);
 - b. *Hover* informativo;
 - c. Filtros interativos (*dropdown*, *sliders*);
 - d. Atualização dinâmica entre *views*.
7. Uso de, pelo menos, uma técnica de visualização avançada
8. Estrutura multi-view coordenada
 - a. Conter múltiplas visualizações complementares;
 - b. Permitir coordenação entre as mesmas;
 - c. Apoiar diferentes níveis de detalhe (overview -> detail on demand)
9. Boas práticas de design visual
 - a. Títulos clares;
 - b. Unidades explícitas;
 - c. Legendas bem posicionadas;
 - d. Hierarquia visual coerente;
 - e. Escolhas cromáticas justificadas.
10. Robustez e performance
 - a. Funcionamento em tempo real;

- b. Filtragens rápidas;
- c. Código organizado;
- d. Estrutura clara.

Dados

Os dados foram retirados do repositório oficial da plataforma Our World in Data ([ver aqui](#)), o que garante veracidade dos dados e informações atualizadas. São abrangidos dados desde 2020 até 2024 de 255 países/regiões divididos nas seguintes categorias:

Identificação e Tempo (Dimensões)

Nome da Coluna	Tipo Técnico	Tipo Analítico	Descrição
iso_code	String (Object)	Categórico Nominal	Código de 3 letras do país (ex: BRA, USA).
continent	String (Object)	Categórico Nominal	Continente da localização.
location	String (Object)	Categórico Nominal	Nome geográfico do país ou região.
date	String (Object)	Temporal	Data da observação (formato AAAA-MM-DD).

Métricas de Casos e Mortes (Fatos Epidemiológicos)

Nome da Coluna	Tipo Técnico	Tipo Analítico	Descrição
total_cases	Float	Numérico o Discreto	Total acumulado de casos confirmados.
new_cases	Float	Numérico o Discreto	Novos casos confirmados no dia.
total_deaths	Float	Numérico o Discreto	Total acumulado de mortes atribuídas à COVID-19.
new_deaths	Float	Numérico o Discreto	Novas mortes no dia.

..._per_million	Float	Número Contínuo	Versões normalizadas das métricas acima por 1 milhão de habitantes.
..._smoothed	Float	Número Contínuo	Média móvel de 7 dias para suavizar flutuações diárias.

Hospitalização e Testagem

Nome da Coluna	Tipo Técnico	Tipo Analítico	Descrição
icu_patients	Float	Número Discreto	Número de pacientes em UTI no dia.
hosp_patients	Float	Número Discreto	Número de pacientes hospitalizados no dia.
total_tests	Float	Número Discreto	Total acumulado de testes realizados.
positive_rate	Float	Número Contínuo	Proporção de testes que deram positivo (0 a 1).

Vacinação

Nome da Coluna	Tipo Técnico	Tipo Analítico	Descrição
total_vaccinations	Float	Número Discreto	Número total de doses administradas.
people_vaccinated	Float	Número Discreto	Pessoas que receberam pelo menos uma dose.
people_fully_vaccinated	Float	Número Discreto	Pessoas que completaram o esquema vacinal inicial.

total_boosters	Float	Numérico Discreto	Doses de reforço administradas.
----------------	-------	-------------------	---------------------------------

Indicadores Socioeconômicos e Demográficos (Contexto)

Nome da Coluna	Tipo Técnico	Tipo Analítico	Descrição
population	Integer	Numérico Discreto	População total da região (em 2023/24).
gdp_per_capita	Float	Numérico Contínuo	PIB per capita (paridade de poder de compra).
life_expectancy	Float	Numérico Contínuo	Expectativa de vida ao nascer.
human_development_index	Float	Numérico Contínuo	IDH do país (escala de 0 a 1).
stringency_index	Float	Numérico Contínuo	Índice de rigor das medidas de isolamento (0 a 100).

Análise Exploratória de Dados

Devido à extensão das features do dataset (71 *features*), a análise exploratória dos dados com o apoio de ferramentas como Python com as bibliotecas Pandas e Plotly torna-se uma parte crucial para o bom entendimento dos dados e, posteriormente, a criação das visualizações.

Para iniciar a exploração e por conta da natureza dos dados, partimos para testar as hipóteses iniciais que “vêm à cabeça” quando o tema da Covid-19 é discutido. As primeiras hipóteses testadas foram do tipo: “a criação da vacina e o impacto no crescimento de casos

e número de mortes”, países mais desenvolvidos lidaram melhor com a pandemia, entre outros.

Variáveis de Saúde

No que diz respeito à análise exploratória das variáveis de saúde, foi construído um sub-dataset (`df_health`) com 15 variáveis relativas à evolução clínica e epidemiológica da pandemia, abrangendo três dimensões principais: casos confirmados, mortalidade e cobertura vacinal. Todas as visualizações foram produzidas com Plotly (`plotly.express` e `plotly.graph_objects`).

As variáveis analisadas foram organizadas em três grupos temáticos:

- **Casos:** `new_cases`, `total_cases`, `new_cases_smoothed`, `total_cases_per_million`
- **Mortalidade:** `new_deaths`, `total_deaths`, `new_deaths_smoothed`, `total_deaths_per_million`
- **Vacinação:** `total_vaccinations`, `people_vaccinated`, `people_fully_vaccinated`

Foi ainda calculada uma variável derivada — o **Case Fatality Ratio (CFR)** — definida como a proporção entre o total de mortes confirmadas e o total de casos confirmados, expressa em percentagem. O CFR é uma métrica epidemiológica amplamente utilizada para avaliar a severidade clínica de uma doença num dado momento: valores elevados indicam que uma maior proporção dos casos confirmados resultou em morte. É importante notar que o CFR é sensível ao nível de testagem — em períodos de baixa capacidade de diagnóstico, os casos são sub-registados, o que tende a inflacionar artificialmente o valor do CFR.

Nessa fase inicial foram aplicadas visualizações do tipo: *scatterplots*, histogramas, gráficos de linha, *treemap* e *choropleth*.

O primeiro gráfico explorado foi um gráfico de linhas com dois eixos Y sobrepostos, representando a evolução global de casos totais e pessoas vacinadas, filtrado para `location == 'World'`. A decisão de usar dois eixos Y distintos deveu-se à diferença de ordem de magnitude entre as duas variáveis em determinados períodos da pandemia. O eixo temporal foi formatado com intervalos de 6 meses para melhorar a legibilidade. Esta visualização permitiu uma leitura intuitiva do desfasamento temporal entre o crescimento de casos e o arranque da campanha de vacinação.

O segundo gráfico normalizou ambas as métricas em percentagem da população mundial (`cases_pct` e `vac_pct`). Esta normalização eliminou o efeito da escala absoluta e permitiu comparar diretamente o alcance da pandemia com o alcance da vacinação numa escala comum. Esta abordagem revelou-se mais rigorosa do que o gráfico de duplo eixo, na medida em que não distorce visualmente a relação entre as duas variáveis através de escalas independentes. O que evidenciou os picos no crescimento dos casos em momentos nos quais houve nova variante da Covid.

Foi produzido um *scatterplot* entre os casos totais e as vacinações totais globalmente, após remoção de valores nulos. O objetivo foi explorar visualmente a relação temporal entre a progressão pandémica e o esforço vacinal global. Dado que as vacinações apenas se iniciaram em finais de 2020, os valores mais elevados de vacinação coincidem com os períodos de maior acumulação de casos, o que gera uma correlação positiva de natureza temporal e não causal.

A visualização mais completa das variáveis de saúde foi construída com `make_subplots`, organizando dois painéis verticais com eixos secundários partilhando o mesmo eixo temporal:

- **Painel superior:** Novos casos (`new_cases_smoothed`) e novas mortes (`new_deaths_smoothed`), representando a dinâmica epidemiológica ao longo do tempo. O uso das versões suavizadas elimina o ruído semanal de reporte.
- **Painel inferior:** Pessoas vacinadas (`people_vaccinated`) e CFR (`cfr_pct`), relacionando o ritmo de vacinação com a evolução da letalidade.

Tal visualização nos evidenciou que o CFR apresenta uma trajetória decrescente pronunciada ao longo do tempo, coincidindo com o aumento da cobertura vacinal, mas também com a melhoria dos protocolos clínicos e com a expansão da capacidade de testagem, o que reduz o sub-registo de casos e, consequentemente, deflaciona o CFR. Esta multicausalidade da evolução do CFR reforçou a necessidade de contextualizar temporalmente qualquer comparação entre países.

Também foi construído um *treemap* hierárquico, onde a área de cada retângulo representa o total de casos do país (top 45 com maior carga) e a cor representa o CFR, numa escala divergente. A hierarquia foi definida por `continent` → `location`, permitindo comparações visuais imediatas tanto dentro de cada continente como entre continentes. O snapshot utilizado corresponde ao último registo temporal disponível por país. Isso nos permitiu concluir que a relação entre carga total de casos e severidade (CFR) não é uniforme: países com elevado número de casos não apresentam necessariamente CFR elevado, e vice-versa. Esta dissociação entre volume e severidade motivou a decisão de tratar estas duas dimensões como variáveis independentes nas visualizações comparativas finais.

Por fim, foi produzido um mapa *choropleth*. O mapa foi construído de forma parametrizável (a variável `metric` pode alternar entre casos totais e CFR), permitindo visualizar geograficamente tanto a carga pandémica absoluta como a severidade clínica por país. O que confirmou a existência de padrões geográficos claros, com assimetrias notórias entre continentes, reforçando a pertinência de incluir a dimensão geográfica nas análises subsequentes e de usar métricas normalizadas por população para comparações internacionais justas, em detrimento dos valores absolutos.

Variáveis Socioeconómicas e Demográficas

No que diz respeito à análise exploratória das variáveis socioeconómicas, o primeiro passo foi construir um sub-dataset (`df_econ`) com as 19 variáveis socioeconómicas e demográficas do dataset original, englobando dimensões como estrutura da população, desenvolvimento económico, capacidade do sistema de saúde, comorbidades e mortalidade pandémica. As visualizações foram produzidas inteiramente com Plotly (`plotly.express` e `plotly.graph_objects`).

As variáveis analisadas foram agrupadas, tematicamente, em 4 grupos:

- Demográfico: `median_age`, `aged_65_older`, `aged_70_older`, `population`, `population_density`
- Desenvolvimento económico: `gdp_per_capita`, `extreme_poverty`, `human_development_index`

- Saúde e Comorbidades: `cardiovasc_death_rate`, `diabetes_prevalence`, `female_smokers`, `male_smokers`, `handwashing_facilities`, `hospital_beds_per_thousand`, `life_expectancy`
- Mortalidade Pandémica: `excess_mortality`, `excess_mortality_cumulative`, `excess_mortality_cumulative_absolute`, `excess_mortality_cumulative_per_million`

Antes da visualização, foram aplicadas transformações logarítmicas (base 10) a variáveis com distribuições muito assimétricas (`population`, `population_density`, `gdp_per_capita`, `extreme_poverty`). Esta decisão foi motivada pelo facto dessas variáveis abrangerem vários níveis de magnitude (por exemplo, populações de dezenas de milhares a milhares de milhões), tornando escalas lineares pouco informativas. Foi também definido um dicionário de *labels* para tornar os gráficos mais legíveis.

Na fase de visualização, os métodos escolhidos foram: histogramas, mapas de calor de correlação e *scatterplots*.

O objetivo do histograma foi avaliar as distribuições para todas as variáveis socioeconómicas em simultâneo, usando `make_subplots`. Esta visualização permitiu perceber a forma das distribuições, seja simetria, assimetria ou a presença de outliers e confirmar se as transformações logarítmicas normalizaram adequadamente as variáveis *skewed*.

Os mapas de calor usaram matrizes de correlação de Pearson em 4 grupos temáticos e visualizados com a escala divergente `RdBu_r` (vermelho-azul). Esta escala foi escolhida pois facilita a leitura imediata da direção e a intensidade das correlações.

Os *scatterplots* exploraram 3 relações diretas entre variáveis:

- `aged_65_older` vs `excess_mortality_cumulative_per_million` (envelhecimento vs mortalidade por milhão)
- `median_age` vs `excess_mortality` (mediana de idade vs mortalidade excessiva)
- `population_log10` vs `excess_mortality_cumulative_absolute` (dimensão do país vs mortalidade absoluta)

A análise efetuada com as variáveis socioeconómicas focou-se em 3 hipóteses centrais:

- **Envelhecimento traduz-se em maior mortalidade pandémica:** esperava-se que países com populações mais velhas (maior `aged_65_older` e `median_age`) apresentassem `excess_mortality` mais elevado.
- **Desenvolvimento económico reflete-se numa mortalidade moderada:** assumiu-se que `gdp_per_capita` e `human_development_index` elevados estariam negativamente correlacionados com pobreza extrema e positivamente correlacionados entre si.
- **Dimensão da população e a mortalidade absoluta são proporcionais:** testou-se se países maiores apresentavam, em termos absolutos, maior `excess_mortality_cumulative_absolute`, o que justificaria o uso de métricas *per million* para comparações internacionais.

Com esta análise exploratória dos dados socioeconómicos chegaram-se a alguns *insights* e decisões de design essenciais.

A análise de correlação revelou que as variáveis demográficas de envelhecimento (`median_age`, `aged_65_older`, `aged_75_older`) são altamente redundantes entre si, algo esperado, mas confirmado visualmente pelo *heatmap*. Esta informação orientou a decisão

de não incluir todas num modelo ou visualização final, optando por `median_age` como variável representativa.

No grupo de desenvolvimento, o heatmap confirmou uma forte correlação negativa entre `gdp_per_capita`, `human_development_index` e `extreme_poverty`, validando que estas variáveis captam dimensões complementares do mesmo construto. Esta redundância será tida em conta no desenho de visualizações comparativas.

A análise de mortalidade excessiva evidencia que `excess_mortality_cumulative` e `excess_mortality_cumulative_per_million` medem realidades distintas: a primeira é dominada por países com grandes populações, enquanto a segunda permite comparações mais justas entre países. O `scatterplot population_log10 vs excess_mortality_cumulative_absolute` tornou este efeito de escala visível, reforçando a decisão de usar métricas normalizadas por população nas análises comparativas finais.

Design

O desenvolvimento do dashboard será orientado por princípios consolidados na área da Visualização de Dados, com o objetivo de garantir clareza, rigor analítico e eficácia perceptiva na análise da relação entre a COVID-19 e indicadores económicos.

Princípios de Design

O design seguirá as diretrizes propostas por Edward Tufte, privilegiando a clareza e a integridade da informação. Será maximizada a **data-ink ratio**, reduzindo elementos visuais não essenciais, de forma a centrar a atenção nos dados relevantes. Em paralelo, será assegurada a **integridade gráfica**, garantindo que escalas e proporções representam fielmente os dados, evitando interpretações enviesadas. Para permitir comparações entre múltiplos países e regiões, recorrer-se-á a **small multiples**, promovendo consistência visual e facilitando a identificação de padrões temporais.

Teorias Perceptivas



A seleção dos elementos visuais terá por base princípios de percepção humana, de modo a otimizar a interpretação da informação. Variáveis quantitativas serão representadas através da posição em eixos comuns, assegurando elevada precisão na leitura dos valores. Elementos como cor e tamanho serão utilizados para suportar o **processamento pré-atentivo**, permitindo identificar rapidamente padrões relevantes. Adicionalmente, serão aplicadas leis de Gestalt, nomeadamente a proximidade e a continuidade, para estruturar a informação e garantir uma leitura fluida das séries temporais.

Teorias da Cor

A cor será utilizada como um canal funcional para organizar a informação e reduzir a carga cognitiva. Serão aplicados esquemas categóricos para distinguir variáveis nominais, esquemas divergentes para representar variações em torno de um ponto de referência (como alterações no PIB) e esquemas sequenciais para comunicar diferentes níveis de intensidade. As escolhas cromáticas terão ainda em consideração critérios de

acessibilidade, assegurando legibilidade para utilizadores com diferentes capacidades visuais.

Mockups e Rascunhos



Implementação

Avaliação

Reflexão Crítica